# You Only Look Once: Unified, Real-Time Object Detection

2024.01.26 이은주

#### Intro

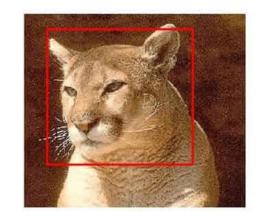
Classification



Cougar

Output: class probability

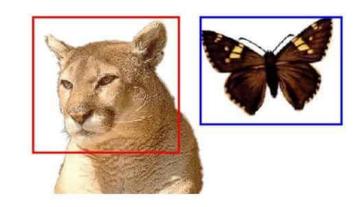
Classification + Localization



Cougar

Output: (x, y, w, h)

**Object Detection** 



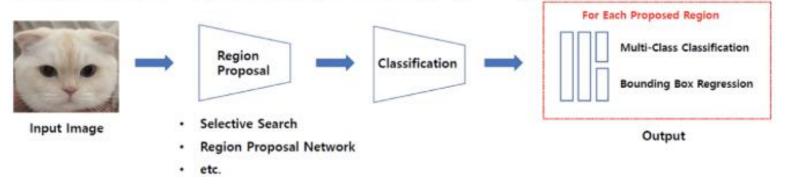
Cougar, Butterfly

Output : class probability + (x, y, w, h)

## Object Detection

이미지 내 모든 위치를 object의 잠재영역으로 보고 각 후보 영역에 대해 class 예측. YOLO 계열, SSD 계열

#### 2-Stage Detector - Regional Proposal와 Classification이 순차적으로 이루어짐.

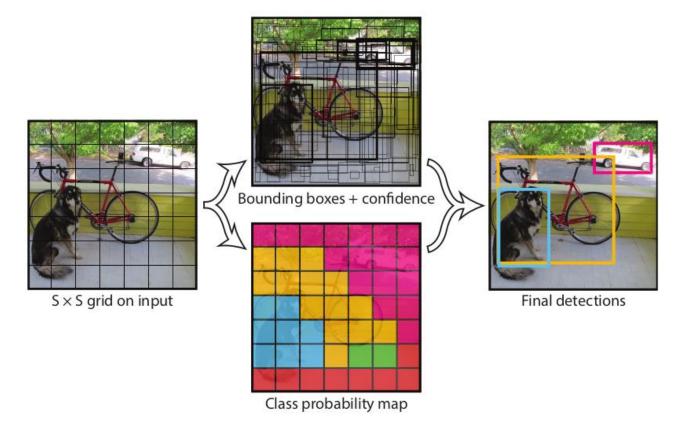


후보 object 위치 제안 후, object class 예측. R-CNN계열

### Yolo

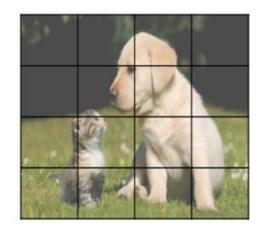
Region proposal, feature extraction, classification, bbox regression

-> one stage detection으로 통합

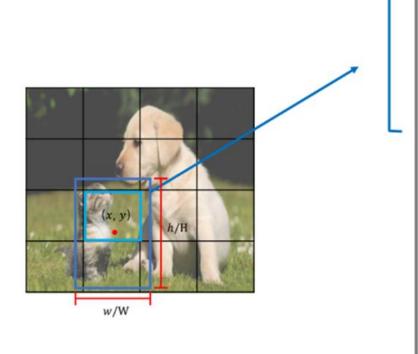


### Yolo 동작과정

예시) S = 4, B = 2, C = 20



Resized image 를 4x4 grid 로 분할



bbox#1

V

W h

Grid cell 마다 bbox 2개씩 예측

bbox의 중심좌표의 위치 (grid cell 기준)

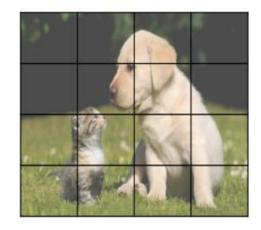
Input image W, H 로 normalize

 $p_c$ :  $Pr(Object) * IOU_{pred}^{truth}$ 

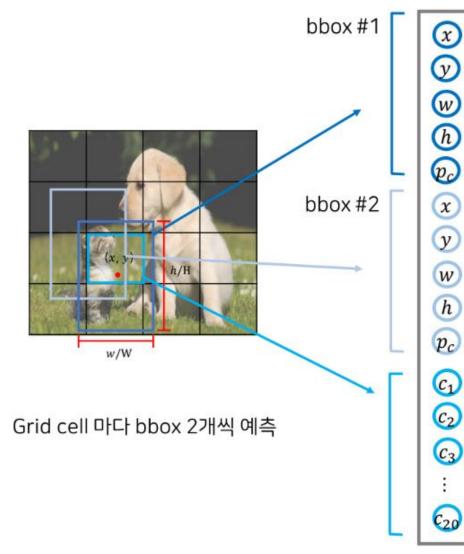
cf. Pr(*Object*) : 물체가 bbox 내에 있으면 1, 없으면 0

### Yolo 동작과정

예시) S = 4, B = 2, C = 20



Resized image 를 4x4 grid 로 분할



bbox의 중심좌표의 위치 (grid cell 기준)

Input image W, H로 normalize

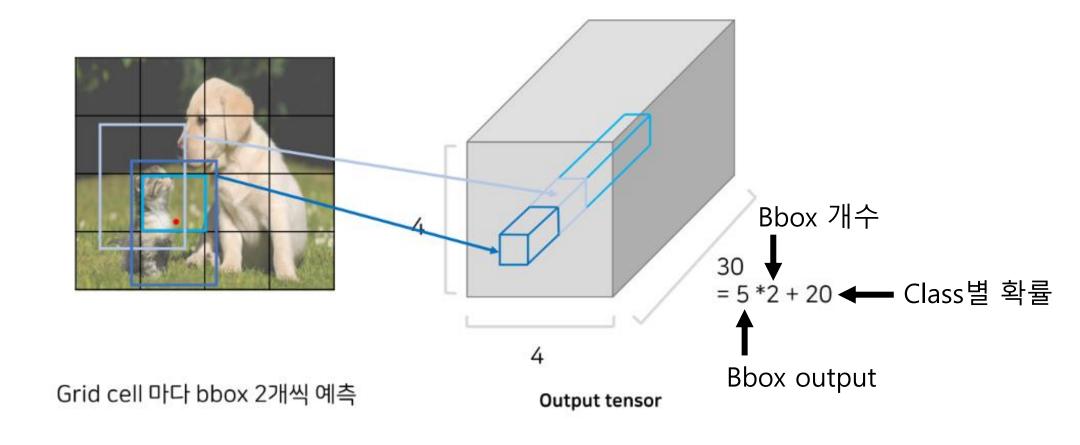
 $p_c$ :  $Pr(Object) * IOU_{pred}^{truth}$ 

cf. Pr(*Object*) : 물체가 bbox 내에 있으면 1, 없으면 0

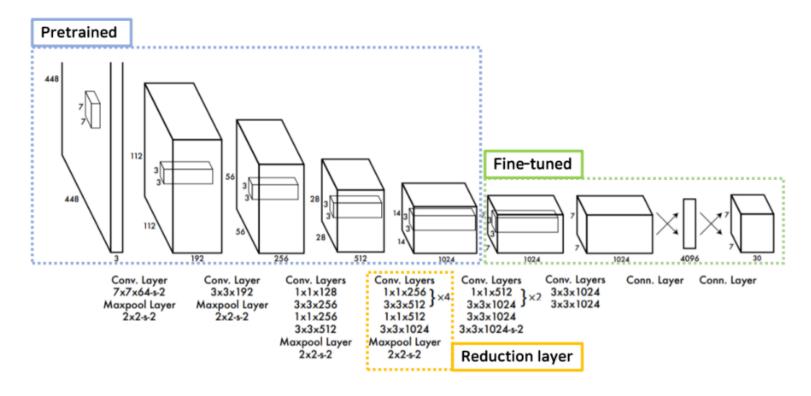
 $Pr(Class_i|Object)$ 

: 물체가 bbox 내에 있을 때, Grid cell에 있는 object가 i번째 class 에 속할 확률

### Yolo 동작과정



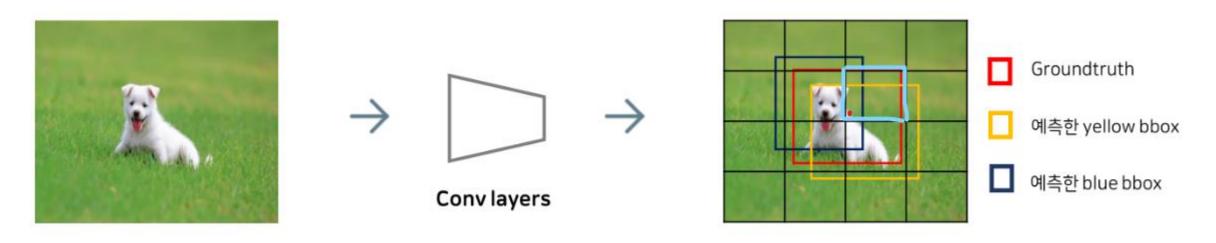
#### Yolo Network



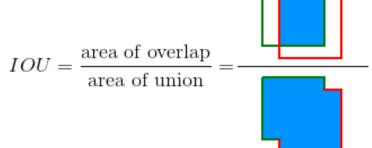
총 24개의 conv layer와 2개의 fc layer로 구성 앞의 20개의 conv layer에 대해서는 1000개 클래스의 ImageNet 데이터셋으로 pretrained 된 부분 뒤에 4개의 conv layer와 2개의 fc layer를 더 붙여서 Pascal VOC 데이터로 Fine tuning 시킨 과정 노란색으로 표시된 중간에 1x1 reduction layer로 연산량 감소

### Training

Input Image



Groundtruth 중심점이 cell 6에 위치 즉, cell 6이 강아지 object 예측하는데 responsible한 cell이 된다.



학습시에는 예측된 bbox중 하나만 사용한다. (한 개 선정 기준 : IOU) 학습 단계에서 Groundtruth와 IOU가 가장 높은 예측 bbox 1개만 사용하여 진행

IOU blue < IOU yellow 이므로 cell 6에서 responsible한 tello box를 표시하여 loss function에 반영

## Training

Train 단계 loss function : MSE

Regression loss

$$\begin{split} &\lambda_{\mathbf{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[ (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ &+ \lambda_{\mathbf{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[ \left( \sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left( \sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \end{split}$$

모든 grid cell에서의 gt box좌표 와 bbox좌표의 오차

Confidence loss

$$egin{aligned} &+\sum_{i=0}^{S^2}\sum_{j=0}^B\mathbb{1}_{ij}^{ ext{obj}}\left(C_i-\hat{C}_i
ight)^2\ &+\lambda_{ ext{noobj}}\sum_{i=0}^{S^2}\sum_{j=0}^B\mathbb{1}_{ij}^{ ext{noobj}}\left(C_i-\hat{C}_i
ight)^2 \end{aligned}$$

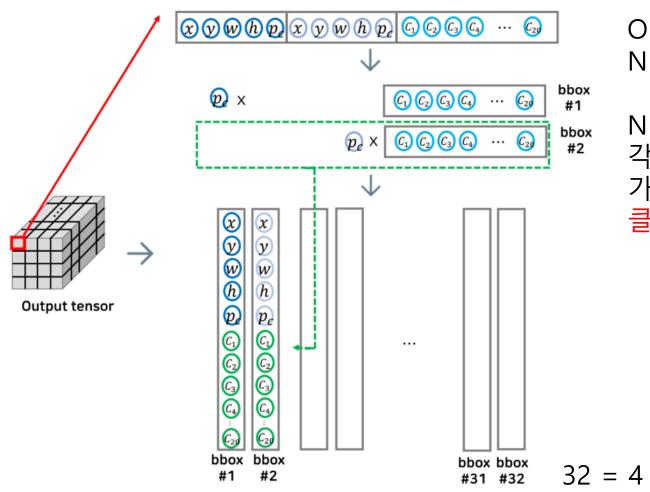
모든 grid cell에서 예측한 class 속할 확률 값과 gt값의 오차

Classification loss

$$+\sum_{i=0}^{S^2}\mathbb{1}_i^{\text{obj}}\sum_{c\in\text{classes}}(p_i(c)-\hat{p}_i(c))^2$$
 모든 grid cell의 confidence

score와 실제 정답과의 차이

i는 cell의 index , j는 bounding box predictor index



Object당 bbox개수가 많아지므로 NMS(알고리즘) 적용

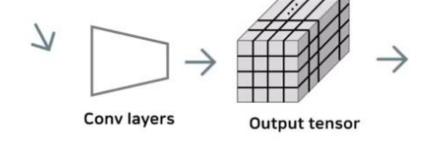
NMS(Non-Maximum Suppression): 각 object에 대해 예측한 여러 bbox 중 가장 예측력 좋은 bbox만 남김 클래스 별로 각각 적용

32 = 4 \* 4 (image size) \* 2 (bbox 개수)





Input Image



Non-Maximum Suppression



나머지 bbox들은 bbox12와 IOU계산 나머지 bbox들은 IOU가 높아 NMS에 의해 제거 됨. bbox12와 bbox13의 IOU가 높다.

즉, 두 bbox는 같은 object를 detect한다는 의미. \_

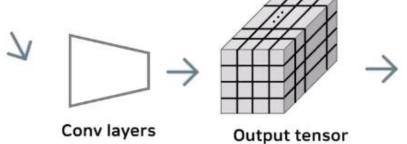
Class 강아지를 가장 잘 예측하는 bbox는 #12 로 결정

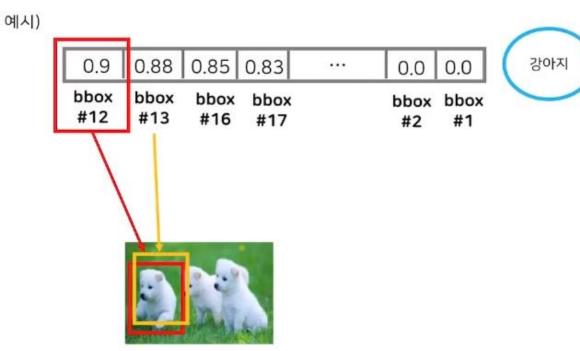
- 나머지 bbox는 bbox#12 와의 IOU 가 높아서 NMS에 의해 모두 제거됨.

2) 같은 class 속하는Object 가 2개인 경우

Non-Maximum Suppression



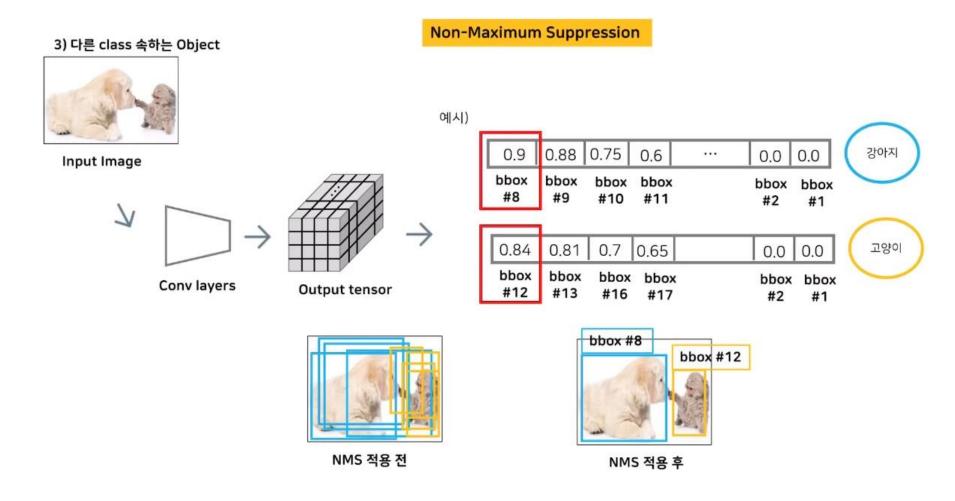




Bbox12와 bbox16은 IOU낮음.

즉, 두 bbox는 다른 object라는 의미. 제거x

Bbox#12 와 bbox#13의 IOU가 높으므로 NMS에 의해 제거됨.



클래스별로 NMS 알고리즘 수행하므로 강아지, 고양이 별도로 진행

## Comparison to Other Real-Time Systems

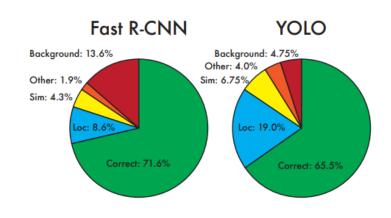
Real-Time Detectors	Train	mAP	FPS
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	155
YOLO	2007+2012	63.4	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21

속도(FPS) : Fast Yolo > Yolo > DPM, RCNN

One stage > Two stage

성능(mAP): Faster-RCNN > Fast-RCNN > Yolo > DPM

One stage < Two stage



Fast R-CNN + Yolo => mAP 3.2% 향상 (mean Average Precision)

	VOC 2007	Picasso		People-Art
	AP	AP	Best $F_1$	AP
YOLO	59.2	53.3	0.590	45
R-CNN	54.2	10.4	0.226	26
DPM	43.2	37.8	0.458	32
Poselets [2]	36.5	17.8	0.271	
D&T [4]	-	1.9	0.051	

AP성능은 Yolo가 다른 모델에 비해 좋음 (Average Precision)